

第一階段 PoC 成果與下一步決策

分散式資料庫架構 × 跨區域驗證 × 決策框架

2026-06-26 | DBA

Outline

- 專案迄今歷程
- 第一階段 PoC 測試數據彙整
- 第二階段 跨區域 / 跨專線執行進度
- 決策框架說明
- 後續推進

專案歷程 ① 研究定義到跨家框架

先定義問題與比較口徑，再建立可重複執行的基礎設施與三資料庫共同工具鏈

時間	階段	重大節點	狀態
2026-03-30~04-10	前期研究	定義分散式 SQL、跨區同鍵寫入、follower read、HA/DR 與九項 survey 評估面向	✅ 完成
2026-04-21~04-27	IaC 與第一版測試鏈	建立多測項部署、HAProxy、VM / Kubernetes 流程及獨立壓測 client {FIXME} Chain 的 flow & Key Point	✅ 完成
2026-04-28~05-05	YugabyteDB 首輪除錯	處理 BenchmarkSQL、bulk load、RF / schema packing 與 HAProxy 問題	✅ 完成
2026-05-06~05-14	三資料庫對標成形	納入 TiDB、CockroachDB、YugabyteDB，統一結果結構與 go-tpc 工具鏈	✅ 完成

此階段完成的是「可比較的工程框架」，早期測試數字不直接納入 v4.7 正式結果。

專案歷程 ② 基準、三節點與治理

將測試從可執行提升為可重現、可追溯、可拆解成本來源

時間	階段	重大節點	狀態
2026-05-18～ 05-21	v4.7 baseline 重構	建立 PoC-DESIGN SSOT、detached suite、gate、marker、summary 與單節點三隔離級對標	✅ 完成
2026-05-22～ 06-02	三節點 controlled experiment	完成 shard × replica × HAProxy 拓樸、12-cell dry-run 與三家 5-cell 結果	✅ N=1 完成
2026-05-20～ 06-04	文件與數據治理	建立模板、AI 協作規範、artifact-first 審計與三家 pipeline-log 對齊	✅ 完成
2026-06-06～ 06-07	Phase isolation	分離 S-BASE、S-K8S、T-THRD、X-CROSS，建立配置宣告、基礎指標確認及指標配置	✅ 完成

正式數字必須能追回測試條件、時間戳、結果檔案與完成標記；缺少來源資料（測試階段）時不予納入參考。

專案歷程 ③ Kubernetes 到跨區驗證

已完成 Kubernetes 對照與跨區技術路徑；正式跨區效能仍受實測結果約束

時間	階段	重大節點	狀態
2026-06-08～06-14	Kubernetes v4.7	由單 cell dry-run 擴充至三資料庫 × limit/unlimit 六組正式 suite	✅ 6/6 完成
2026-06-08～06-17	跨區設計與前置開發	建立 GCP VM、六節點部署、placement、WAN、chaos、failover 與 pre-flight 規格	🟡 框架完成 部分僅 dry-run
2026-06-18～06-19	IDC ↔ GCP 實際驗證	修正 IaC、gate、防火牆與 YugabyteDB placement，三家完成真六節點前期測試	✅ smoke 完成
2026-06-21～06-22	Determinism 收斂	W=4 重跑浮動過大，改採同 cluster、freeze/unfreeze、變異量/變異參數 與 W=128 baseline	🟡 進行中

決策界線：可確認六節點跨區交易路徑可行；正式跨家排序須等 W=128、R2～R5 中位數 / 變異係數與回復流程驗收結論。

三家資料庫導入定位

資料庫	第一階段觀察	導入定位
TiDB	VM 與 K8s 吞吐表現較佳；K8s retention 較高	方便優先進入應用情境對接
CockroachDB	一致性需求較強（SSI 預設）；SI / SSI 模式下 retry 與效能成本明顯	保留觀察 ：應用層需評估 Error Handling 容忍度與交易模式
YugabyteDB	VM + HAProxy 表現為佳；K8s 結果目前不宜直接作為導入結論	保留觀察 ：K8s 部署仍需調校與驗證，VM 路徑可進入評估

同 IDC / 同硬體 基準 — vm-3node-haproxy-3s3r-rc, t=128 mean tpmC

{FIXME} 測試架構圖補完；db component intro；各節點較重損耗

TiDB	YugabyteDB	CockroachDB
≈ 26,900	≈ 15,600	≈ 15,000

本組數字為 controlled experiment 基準（VM 現況資源 × 3 node 拓樸）；不直接代表各家「拿出來就跑」的生產表現；不具任何採購驗收指標用。
商業實體 / 授權 / 採購層面議題需另案審查。

VM 與 Kubernetes 效能差異

K8s 化對 TiDB 與 CockroachDB 屬可接受範圍；YugabyteDB 在 K8s 下退化顯著，列為調校與驗證項

資料庫	S-BASE (VM) tpmC	S-K8S unlimit tpmC	S-K8S limit tpmC	unlimit / VM	limit / VM	p99 unlimit Δ	p99 limit Δ
TiDB v8.5.2	26,947	23,442.9	15,751.9	87.0 %	58.5 %	+17 %	+111 %
CockroachDB v26.2	15,033	12,196.7	6,493.5	81.1 %	43.2 %	+27 %	+192 %
YugabyteDB 2025.2	15,632	2,997.6	1,604.5	19.2 % ⚠	10.3 % ⚠	+669 %	+1556 %

觀察解讀

- TiDB / CockroachDB：K8s unlimit 保留率 81–87 %，屬可接受範圍；limit 情境大幅衰退反映資源壓縮
- YugabyteDB：K8s unlimit 僅 19.2 %、p99 +669 %。成因推論：YSQL + DocDB 雙 process 在 K8s pod IPC + CPU contention 放大。**成因未定位，列後續調校項**
- S-BASE ↔ S-K8S 可直接比較（同 workload W=128 t=128）

跨區域 / 跨專線進度

| {FIXME} 架構圖示說明解釋 P-A/P-B placement

✓ 已完成

- 技術議題定案 (GCP 5 VM 拓樸、placement P-A/P-B、Chaos Engineering 等)
- IaC、playbook、suite scripts、chrony drift gate (drift_median 0.017 ms ; 時間偏移 between IDC & GCP)
- 06-18~06-19 : 修正 IaC / 防火牆 / YugabyteDB placement, 三家 DB / 六節點前期測試驗證
- 06-21~06-22 : Determinism v2 — 同 cluster R1-R5、scheduler / balancer freeze

● 待執行

- 調度 scheduler (開/關)、round-only runner、Warmup、Placement (replica / lease 位置)、測試結果彙整
- 回到 W=128 正式基準量測
- Failover 與 Chaos Engineering 實際驗證

X-CROSS 初步結果 (06-22~06-23)

W=4 framework 驗證；不與 S-BASE/S-K8S 直接對比 · 同 cluster 5 rounds、W=4、16 threads、每 round 5 min、controller = .31 (IDC client)

資料庫	R1	R2	R3	R4	R5	中位數 (有效輪)	CV
TiDB v8.5.2	9,525.5	9,553.2	9,786.9	9,393.2	9,530.8	9,566.0 (R2-R5)	1.67 %
CockroachDB v26.2	8,409.5	8,055.3	7,902.5	7,720.9	7,472.3	7,787.8 (R2-R5)	3.23 %
YugabyteDB 2025.2	102.0	226.9	6,424.2	6,259.3	6,206.2	6,296.6 (R3-R5)	1.82 %

已確認結論

- 06-21 觀察到的 $\pm 526\%$ / $\pm 50\%$ 變異主因為「每輪重新部署」造成 placement / cache / scheduler 狀態異動，與 W=4 contention 為兩個獨立來源
- 同一 cluster 連跑時，三家 W=4 R2-R5 (或 YBDB R3-R5) 的 $CV \leq 5\%$ ，重現性已建立
- YBDB Idle=0 解法：gate 改用 `get_load_move_completion=100%`；timed run 前 `set_load_balancer_enabled=0`
- CRDB lease gate SQL 改用 `SHOW RANGES FROM DATABASE tpcc WITH TABLES, DETAILS` (v26.2 相容)

Caveat：W=4 framework / contention 驗證 $\neq$ 正式基準；R2-R5 (YBDB R3-R5) $CV \leq 5\%$ 已建立但不可作跨家排名；後續需回 W=128。

建議決策框架

不是選一家，是先界定 application 條件、再排序候選；僅提供做決策框架參考依據用

分類	內容	處置
短期候選	TiDB	優先進入應用情境對接，無門檻
保留觀察	CockroachDB	依一致性需求、Error Handling 容忍度、維運成本評估
保留觀察	YugabyteDB	VM 路徑可評估；K8s 路徑需先完成部署層級調校與驗證
暫不作結論	跨區域場景、K8s 退化未定位項	待下一階段 W=128 測試數據與調校產出再回頭評估

Application 需要確認的議題

- 1. 交易一致性需求：是否需要 SERIALIZABLE / SSI？是否可接受 READ COMMITTED & 產品設計架構轉 CAP 的複雜度及可行性？
- 2. 可接受延遲：在尖峰 t=128 等級負載下，p99 是否需要 500ms / 1s / 2s 以內？
- 3. retry / timeout 行為：應用層是否能接受 SI / SSI 模式下的 retry 機制？
- 4. RTO / RPO：跨區域 failover 是否需要 < 30s RTO？是否容許資料 lag？
- 5. 連線層 / 交易模式調整：是否能配合 HAProxy / PgBouncer / 連線池與短交易模式？

後續推進階段

短期 EX: Y26/07	中期	決策
{FIXME} 補完完整測試時間描述	A-S / A-A-RO / A-A 三個 workload profile × P-A/P-B placement × 三家資料庫，依檢驗指標分批 / 量測	Application owner 完成五項議題確認
W=4 框架已驗，接 W=128 基準	Failover 與 Chaos Engineering 測試	原廠後勤對接狀況說明
freeze/unfreeze、round-only runner、暖機、placement gate 全部通過 審查	跨區域 analytics 第二份報告	
X-CROSS 完成 determinism 流程 驗收，啟動正式 W=128 基準 量測	補齊 YugabyteDB K8s 退化成因調查 (P-A/P-B、A-S/A-A-RO/A-A)	